



AGENTE INTELIGENTE PROTOTIPO PARA LA TOMA DE DECISIONES EN MERCADOS DE FUTUROS DE ELECTRICIDAD DESDE EL PUNTO DE VISTA DE COMPRADORES NO REGULADOS: CASO COLOMBIANO

Documento de Propuesta de trabajo integrador

JHON FERNANDO TASCÓN VELASCO
202500665
tascon.jhon@correounivalle.edu.co

JUAN SEBASTIAN CHACÓN CORREA
202500417
juan.chacon@correounivalle.edu.co

Director: Diego Fernando Manotas Duque, Ph. D.
diego.manotas@correounivalle.edu.co

Director: Orlando Joaqui Barandica, Ph. D.
Orlando.joaqui@correounivalle.edu.co

Facultad de Ingeniería
Escuela de Ingeniería de Sistemas y Computación
Escuela de Ingeniería Industrial
Programa Académico de Maestría en Analítica e Inteligencia de Negocios
Cali, octubre 16 de 2025

Contenido

1. INTRODUCCIÓN	3
2. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA	4
3. JUSTIFICACIÓN.....	5
4. OBJETIVOS.....	7
4.1 OBJETIVO GENERAL.....	7
4.2 OBJETIVOS ESPECÍFICOS	8
5. MARCO REFERENCIAL	8
5.1 ESTADO DEL ARTE.....	8
6. METODOLOGÍA.....	10
6.1 ACTIVIDADES A REALIZAR Y RESULTADOS ESPERADOS	10
6.2 CRONOGRAMA DE ACTIVIDADES.....	12
7. PRESUPUESTO	12
7.1 PRESUPUESTO GENERAL.....	12
7.2 PRESUPUESTO DETALLADO.....	12
8. REFERENCIAS	14

Listado de Tablas

Tabla 1. Actividades y resultados esperados con relación a cada objetivo específico.....	11
Tabla 2. Cronograma de Actividades	12
Tabla 3. Presupuesto general del proyecto.	12
Tabla 4. Presupuesto de personal.....	13
Tabla 5. Presupuesto de Hardware.....	13
Tabla 6. Presupuesto de Software.....	13
Tabla 7. Presupuesto de papelería y otros rubros.....	13

Listado de Figuras

Figura 1. Fases para desarrollar en el proyecto	10
---	----

1. INTRODUCCIÓN

En un entorno eléctrico tan dinámico, la gestión eficiente de los costos de la electricidad se ha convertido en un factor importante para la sostenibilidad y competitividad de las grandes empresas. La volatilidad inherente en los precios de este *commodity*, impulsado por una compleja interacción de factores climáticos, regulatorios y de mercado, presenta un desafío constante para los compradores no regulados. En Colombia, se presenta una situación particular, debido a la alta dependencia de fuentes hídricas y a un mercado de derivados aún en desarrollo. Por esto, la capacidad que tengan los actores de anticipar y reaccionar estratégicamente a estos cambios en el mercado eléctrico, conlleva a una necesidad fundamental para mitigar los riesgos financieros y asegurar la estabilidad operativa a largo plazo, además de las ventajas competitivas que les otorga un mejor manejo de sus recursos.

Para abordar esta oportunidad, el presente trabajo propone el desarrollo de un prototipo de agente inteligente basado en técnicas de aprendizaje por refuerzo profundo (*Deep Reinforcement Learning*), que apoye la toma de decisiones de los compradores no regulados de electricidad en el mercado colombiano de futuros de electricidad. Se busca que este agente, entrenado con datos históricos del mercado colombiano, incorporando variables económicas, regulatorias y o energía que impactan el precio de la electricidad, analice y aprenda de forma autónoma estrategias de compra o venta (Demir, 2023) en el mercado de futuros de energía, con el fin de minimizar los riesgos que trae la volatilidad del mercado eléctrico colombiano. El objetivo es ofrecer una herramienta de inteligencia aumentada que potencie el juicio humano, permitiendo a los analistas concentrarse en la interpretación estratégica mientras el agente se encarga del análisis complejo y la identificación de oportunidades, en un mercado aún en consolidación (Rita Uchenna Attah et al., 2022).

Históricamente, la gestión de riesgos en los mercados eléctricos se ha apoyado en metodologías y técnicas cuantitativas que han evolucionado en el tiempo. Los modelos econométricos tradicionales, como las series de tiempo (ARIMA) y modelos de volatilidad (GARCH), han sido los primeros enfoques utilizados para tal fin, identificando patrones en el comportamiento de los precios. Sin embargo, estos modelos son limitados en cuanto a su capacidad para capturar dinámicas no lineales o cambios abruptos característicos en los mercados energéticos, abriendo paso a técnicas de análisis más avanzada (Weron, 2014).

Con la llegada de la inteligencia artificial, técnicas de aprendizaje automático y las redes neuronales, representaron una mejora notable en la precisión de los pronósticos de precios. Sin embargo, estos modelos a menudo separan la predicción de la acción, operando bajo un paradigma de "predecir y luego decidir", separándose de la estrategia de acción. Es en este contexto donde emerge el aprendizaje por refuerzo profundo (*Deep Reinforcement Learning* o DRL), una metodología que no solo predice el comportamiento del mercado, sino que aprende directamente cuál es la mejor política de decisión para alcanzar un objetivo a largo plazo en entornos complejos e inciertos (Hambly et al, 2021).

La metodología propuesta para este proyecto sigue un ciclo de vida estructurado de análisis de datos, que abarca desde la comprensión del negocio y los datos hasta el modelado y la evaluación de los resultados. En una primera etapa, se construirá un datamart que centralizará y preparará la información histórica relevante del mercado eléctrico colombiano, incluyendo variables económicas, regulatorias y energéticas. Posteriormente, se diseñará un entorno de simulación donde el agente inteligente interactuará y aprenderá. Utilizando un algoritmo de DRL, el agente será entrenado para identificar las acciones de compra o venta más adecuadas en función de los estados del mercado, con el fin de maximizar una recompensa definida, como la rentabilidad ajustada por riesgo.

Este documento está estructurado de la siguiente manera: primero, se presenta el planteamiento del problema y la

justificación del proyecto. A continuación, se definen el objetivo general y los objetivos específicos que guían la investigación. Posteriormente, se expone el marco referencial, que incluye una revisión del estado del arte. Luego, se detalla la metodología a seguir, el cronograma de actividades y el presupuesto estimado para el desarrollo del trabajo. Finalmente, se incluye el listado de referencias bibliográficas consultadas.

2. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA

En los mercados de materias primas contemporáneos, la electricidad se ha consolidado como uno de los activos más volátiles, presentando fluctuaciones de precios que superan a las de otros commodities energéticos como el petróleo o el gas natural. Esta volatilidad intrínseca, derivada de la incapacidad de almacenar energía a gran escala y de la necesidad de un balance instantáneo entre oferta y demanda, genera un riesgo financiero sustancial para los participantes del mercado, especialmente para los grandes consumidores. En consecuencia, la gestión de este riesgo a través de instrumentos derivados, como los contratos de futuros, no es una opción, sino una necesidad estratégica para garantizar la competitividad y la estabilidad operativa (Majcher et al., 2021).

Si bien esta dinámica de volatilidad es compartida a nivel mundial, en Colombia adquiere matices particulares debido a su estructura energética y a factores locales que amplifican los riesgos, donde los precios pueden fluctuar drásticamente debido a condiciones climáticas (Ministerio de Minas y Energía, 2021) y (Valora Analitik, 2025), e interrupciones en la red o cambios regulatorios en el sector energético. Para mitigar estos riesgos, los agentes (generadores, comercializadores y compradores) recurren a diferentes instrumentos financieros, entre ellos los mercados futuros de electricidad, anteriormente mencionados, los cuales permiten a los participantes comprar o vender contratos de suministro de energía eléctrica para entrega en una fecha futura a un precio acordado en el presente.

Sin embargo, la eficacia de este instrumento en Colombia enfrenta un obstáculo fundamental puesto que se encuentra en una etapa incipiente, con baja liquidez y una limitada participación de compradores no regulados, lo cual se traduce en mayor exposición al riesgo por parte de estos actores (Derivex S.A. & Cámara de Riesgo Central de Contraparte de Colombia S.A., 2018). Además, la matriz energética del país depende en más de un 65 % de fuentes hidroeléctricas, lo que genera una alta sensibilidad a fenómenos climáticos como El Niño y La Niña (Ministerio de Minas y Energía, 2021). Estos factores, sumados a las reformas regulatorias en curso por parte de la CREG (COMISIÓN DE REGULACIÓN DE ENERGÍA Y GAS, 2024), intensifican la incertidumbre del mercado y refuerzan la necesidad de herramientas inteligentes de apoyo a la decisión.

La necesidad de gestionar los riesgos del mercado eléctrico ha impulsado el desarrollo progresivo de metodologías cuantitativas a lo largo del tiempo. Inicialmente, se emplearon modelos econométricos tradicionales, como las series de tiempo (ARIMA) y los modelos de volatilidad (GARCH), que buscaban capturar patrones estadísticos en los precios. Sin embargo, su capacidad para modelar las dinámicas no lineales y los cambios abruptos de los mercados energéticos modernos es limitada (Weron, 2014). Como respuesta a estas limitaciones, las técnicas de Machine Learning (ML), como las Redes Neuronales y los Modelos de Ensamble, marcaron un gran avance al mejorar notablemente la precisión de los pronósticos. A pesar de su éxito predictivo, estos modelos de ML a menudo operan bajo un paradigma de "predecir y luego decidir", separando el pronóstico de la estrategia de acción. La frontera actual busca integrar ambos procesos, llevando al surgimiento de metodologías que no solo predicen, sino que aprenden directamente cuál es la política de decisión óptima en entornos complejos.

Es en este punto donde el Aprendizaje por Refuerzo Profundo que maximiza un objetivo a largo plazo, como el retorno ajustado por riesgo. A diferencia de los modelos supervisados, el DRL es ideal para problemas de decisión secuencial en entornos dinámicos e inciertos, lo que lo hace especialmente adecuado para la gestión de portafolios y la cobertura de riesgo, un enfoque que ha ganado una tracción considerable en la investigación financiera cuantitativa (Hambly et al., 2021), sin excluir el sector energético, especialmente en estrategias de trading de

futuros, gracias a su capacidad para gestionar entornos volátiles y complejos de forma dinámica y adaptativa (Demir, 2023).

Considerando el desafío global de la volatilidad en los mercados eléctricos, el potencial demostrado por el Deep Reinforcement Learning para la toma de decisiones, y las condiciones particulares de alta volatilidad hidroclimática y baja liquidez del mercado de derivados en Colombia, este trabajo integrador busca responder a la siguiente pregunta:

¿Cómo desarrollar un agente inteligente prototipo basado en *deep reinforcement learning* para la compra y venta en el mercado colombiano de futuros de energía eléctrica, que apoye la toma de decisiones de los compradores no regulados de electricidad?

Por lo cual, se propone que el agente inteligente prototipo sea capaz de:

1. Conectarse a la base de datos que permita extraer información que pueda afectar el precio de futuros de la energía: noticias económicas, políticas, históricos de precios, etc.
2. Con base en la información anterior, y en el histórico de precios, usar herramientas de Machine Learning, Series temporales o Deep Learning para predecir los precios y su comportamiento.
3. Construir el agente que permita, mediante Deep Reinforcement Learning (DRL), qué tipo de contratos comprar o vender, cuándo hacer las operaciones y los plazos para poder obtener los mejores beneficios y así, generar estrategias para la toma de decisiones en los mercados de futuros de electricidad en Colombia.

El desarrollo del prototipo se realizará utilizando datos históricos reales del mercado eléctrico colombiano, lo cual permitirá simular escenarios representativos y evaluar el desempeño del agente inteligente en condiciones similares a las del mercado nacional.

Finalmente, desde una perspectiva ética, este proyecto se enmarca en el concepto de inteligencia aumentada, entendida como una tecnología que complementa, pero no reemplaza, el juicio humano. El agente propuesto busca apoyar a los analistas y tomadores de decisiones en sus labores diarias, automatizando tareas repetitivas y analíticas para que los expertos puedan así concentrarse en la interpretación estratégica de la información. De esta manera, se espera contribuir a una toma de decisiones más ágil, informada y responsable en un sector esencial para el desarrollo económico del país.

3. JUSTIFICACIÓN

Los mercados energéticos, y en particular los de futuros, enfrentan una transformación significativa marcada por una creciente volatilidad en los precios. Este fenómeno, impulsado en gran medida por la integración de fuentes de energía renovables intermitentes y eventos geopolíticos, ha convertido la predicción de precios en un desafío cada vez más complejo (Demir, 2023). En respuesta, los participantes del mercado, como los generadores y grandes consumidores (GENCOs), necesitan desarrollar estrategias sofisticadas que van más allá de la simple cobertura (hedging), buscando activamente beneficios y una gestión de riesgos dinámica (Wang et al., 2024). En este escenario, los derivados financieros, como los futuros de electricidad, se consolidan como herramientas indispensables para manejar los impactos que se generan por la incertidumbre y la volatilidad en los precios de este tipo de energía.

Paralelamente, los avances en inteligencia artificial han abierto nuevas fronteras para el diseño de estrategias de mercado. Modelos que van desde el Aprendizaje Automático (Machine Learning) hasta el Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning, DRL) permiten apoyar o automatizar la toma de decisiones en los inciertos y complejos entornos de mercado actuales (Conegundes & Pereira, 2024);(Islam, 2024). Entre las aplicaciones claves de estas técnicas, se incluyen el desarrollo de estrategias para maximizar beneficios, la

optimización de la cobertura para mitigar riesgos (incluso usando enfoques multiagente para productores) (Massahi & Mahootchi, 2024), la exploración de oportunidades de arbitraje entre mercados o mediante almacenamiento (Lami et al., 2025), y la operación óptima de activos físicos como baterías en función de las señales del mercado (He et al., 2024).

En Colombia, el mercado eléctrico colombiano presenta un conjunto de particularidades que magnifican el riesgo para los compradores no regulados y lo convierten en un caso de estudio ideal:

- **Alta Dependencia Hidrológica:** La matriz energética de Colombia depende en más de un 65% de la generación hidroeléctrica. Esto la hace extremadamente vulnerable a fenómenos climáticos cíclicos como El Niño-Oscilación del Sur (ENOS) (Ministerio de Minas y Energía, 2021). Durante los periodos de sequía (El Niño), la escasez de agua dispara los precios en el mercado spot a niveles extremos, generando una enorme incertidumbre y riesgo financiero para los compradores que no tienen una estrategia de cobertura robusta (Restrepo-Trujillo et al., 2022).
- **Mercado de Futuros en Desarrollo:** A diferencia de mercados más maduros, el mercado de futuros de energía en Colombia (centralizado en la plataforma Derivex) es relativamente joven. Esto implica una menor liquidez, lo que ha sido identificado como una ineficiencia de mercado que dificulta la gestión activa del riesgo para los comercializadores y grandes (Arias et al., 2024). La escasez de datos históricos largos agrava el problema, limitando la efectividad de los modelos predictivos tradicionales.
- **Ineficiencias en el mercado eléctrico colombiano:** El mercado de electricidad en Colombia no está ajeno a ineficiencias, lo cual expone a los consumidores a riesgos significativos y sobrecostos. El sistema de contratos extrabursátiles (OTC) enfrentan discriminación de precios y problemas de accesibilidad, lo que deja a los usuarios vulnerables al riesgo de mercado (Arias et al., 2024). Además, el mercado opera como un oligopolio con evidencia de concentración y colusión implícita, en el que los generadores pueden seguir estrategias de precios de agentes con mayor capacidad instalada (Marin & Marin, 2022).
- **Vulnerabilidad del Comprador No Regulado:** Los grandes consumidores industriales (compradores no regulados) están directamente expuestos a la volatilidad de los precios de la electricidad. A diferencia de los generadores, muchos de estos actores carecen de las herramientas sofisticadas y los equipos especializados para una gestión activa del riesgo de precios, operando a menudo con estrategias estáticas o heurísticas simples que resultan insuficientes ante la dinámica del mercado (Rodríguez et al., 2022).

Este conjunto de factores crea una necesidad apremiante: el desarrollo de herramientas inteligentes que puedan operar eficazmente en un entorno de alta incertidumbre, con datos históricos limitados, condiciones climáticas cambiantes y diferentes atributos que pueden cambiar las condiciones del mercado.

Por lo anterior, el presente proyecto propone el uso de *Deep Reinforcement Learning* (DRL), ya que este conjunto de técnicas ofrecen ventajas fundamentales sobre otros enfoques (como el Machine Learning supervisado o modelos econométricos) por las características del problema planteado: el objetivo no es solo predecir el precio, sino decidir y evaluar la mejor estrategia (comprar, vender, esperar) en cada momento para maximizar una recompensa a largo plazo (o minimizar un costo o riesgo), teniendo en cuenta múltiples factores o variables de decisión, lo cual es ideal para mercados dinámicos. Investigaciones en simulación muestran consistentemente que el uso de DRL puede superar estrategias de referencia y adaptarse a diferentes condiciones, ya que su naturaleza parte de aprender de la experiencia y ajustarse continuamente a las variaciones del mercado eléctrico, influenciado por factores dinámicos como el clima, interrupciones en la red y modificaciones regulatorias. Esta capacidad de aprendizaje y adaptación en tiempo real es una ventaja clave sobre modelos más estáticos, especialmente para la toma de decisiones en contratos de futuros (Ansari et al., 2022) y (Pan & Jing, 2025). Entre las ventajas del DRL, se tienen:

- **Capacidad de adaptación a la dinámica del mercado:** los agentes DRL pueden ajustar su estrategia en función de las condiciones del mercado en tiempo real, aprendiendo continuamente de nuevas

observaciones, lo cual es esencial en mercados de futuros con alta volatilidad e incertidumbre (Pereira et al., 2024)

- **Mejor rendimiento financiero en simulaciones frente a estrategias tradicionales:** modelos como DQN, A3C y SAC han superado estrategias como *Buy-and-Hold* o reglas heurísticas en mercados simulados de futuros de energía y commodities, incrementando la rentabilidad media y reduciendo el riesgo. Por ejemplo, en el estudio de (Massahi & Mahootchi, 2024), el agente basado en Double DQN obtuvo un retorno medio mensual del 6,3 %, frente al 2,1 % alcanzado por la estrategia *Buy-and-Hold*. Asimismo, Pan & Jing (2025) reportan que el uso del algoritmo SAC permitió una reducción del 17 % en el valor en riesgo (VaR) y un aumento del 12 % en el *Sharpe ratio* en comparación con una política estática basada en reglas fijas.
- **Manejo de información parcial y ambientes complejos:** los mercados de futuros eléctricos son entornos parcialmente observables, y DRL es capaz de operar bajo estos esquemas modelando el problema como un POMDP, lo que permite tomar decisiones óptimas incluso sin conocer completamente el estado del entorno (Ansari et al., 2022).
- **Flexibilidad para incorporar múltiples variables:** DRL puede integrarse con señales hidrológicas, precios spot, tendencias macroeconómicas y variables regulatorias, lo que mejora la capacidad predictiva y la generación de políticas robustas de compra/venta de contratos (Lami et al., 2025).
- **Aplicabilidad a entornos multiagente:** algoritmos como Dual-Q MADDPG permiten modelar múltiples actores del mercado (por ejemplo, varios compradores y generadores), lo que facilita simular interacciones competitivas en subastas de contratos futuros, mejorando la calidad estratégica del agente (Wang et al., 2024)
- **Capacidad de aprender sin supervisión explícita:** a diferencia de ML supervisado, el DRL no requiere etiquetas, sino que aprende directamente de las recompensas obtenidas por sus acciones, lo cual lo hace ideal para entornos donde no hay datos históricos de decisiones óptimas, como es el caso de muchos compradores no regulados en Colombia (Islam, 2024).

El desarrollo de este trabajo aporta un componente innovador que aporta a la gestión empresarial. La creación de un agente especializado en la adquisición de energía no solo representa una mejora incremental en los procesos de compra, sino que introduce un nuevo paradigma de gestión proactiva y basada en datos. Esta herramienta permitirá a las organizaciones no solo reaccionar a las condiciones del mercado, sino anticiparse a ellas, asegurando mejores condiciones contractuales y transformando un centro de costo tradicional en una fuente de eficiencia y valor económico sostenible.

En este sentido, el uso de *Deep Reinforcement Learning* no solo representa un avance tecnológico, sino también una respuesta estratégica ante los desafíos específicos del mercado colombiano de futuros de energía. La capacidad del DRL para operar con información parcial, aprender en entornos dinámicos y adaptarse a señales volátiles resulta especialmente valiosa para los compradores no regulados, quienes carecen de herramientas avanzadas para gestionar su riesgo de compra de energía. Así, el presente proyecto busca aprovechar estas ventajas para diseñar y entrenar un agente inteligente que apoye la toma de decisiones estratégicas, contribuyendo tanto a la eficiencia operativa como a la consolidación de prácticas modernas para estos problemas.

4. OBJETIVOS

4.1 Objetivo General

Desarrollar un agente inteligente prototipo basado en *Deep Reinforcement Learning* (DRL) que apoye la toma de decisiones de los compradores no regulados en el mercado colombiano de futuros de electricidad.

4.2 Objetivos Específicos

- 1) Construir un *datamart* que integre las diferentes características que influyen en el mercado de futuros de energía eléctrica en Colombia para el caso de los compradores no regulados de electricidad.
- 2) Entrenar un modelo de decisión basado en *Deep Reinforcement Learning* (DRL) para la compra y venta de contratos en el mercado colombiano de futuros de electricidad por parte de empresas compradoras no reguladas.
- 3) Evaluar el rendimiento del agente prototipo en los resultados de la estrategia de compra y venta en los mercados futuros de energía eléctrica en Colombia.

5. MARCO REFERENCIAL

5.1 Estado del Arte

En el proceso de revisión de literatura se realiza una división por algoritmos o técnicas utilizadas en el proceso de trading o compra/venta en el mercado de energía, especialmente en el de futuros de electricidad. A continuación, mencionamos las técnicas más utilizadas.

Machine Learning (ML)

El Machine Learning se utiliza fundamentalmente para la predicción de precios, una tarea esencial para cualquier estrategia de trading. Los pronósticos precisos son necesarios para optimizar la relación riesgo-recompensa de las estrategias de arbitraje (Demir, 2023).

La investigación de (Demir, 2023) evalúa exhaustivamente varios modelos de ML para la predicción de precios en mercados de corto plazo, que son relevantes para la liquidación de futuros. Entre los modelos analizados se encuentran:

- Modelos de regresión lineal y de árbol: Se comparan modelos como LASSO, Random Forest (RF) y Gradient Boosting (GB) para la predicción de precios en el mercado de balance (BAL).
- Ingeniería de características (Feature Engineering): Una de las contribuciones clave es la propuesta de usar indicadores técnicos (TIs), como las Bandas de Bollinger y los indicadores de Momentum, para capturar los sesgos de comportamiento de los traders y mejorar la precisión de los pronósticos en el mercado diario (DAM). Se demuestra que la inclusión de estos TIs reduce el error cuadrático medio (RMSE) de los modelos de pronóstico hasta en un 5.42%

En (Waldow et al., 2021) se muestra que la combinación de modelos de ML (como XGBoost integrados con técnicas de SMOTE y optimización NSGA-II) generan señales de trading robustas que superan a las estrategias tradicionales, lo cual es aplicable al contexto de futuros de electricidad.

Deep Learning (DL)

El Deep Learning (DL) representa una evolución del ML, empleando redes neuronales profundas para capturar patrones más complejos y no lineales en los datos del mercado. Sus aplicaciones en el contexto de los mercados energéticos se centran en la mejora de los pronósticos y la generación de datos sintéticos.

- Mejora de Pronósticos: En la predicción de precios del mercado de balance (BAL), las Redes Neuronales Profundas (DNN) han demostrado superar a otros modelos de ML, obteniendo los menores errores de pronóstico (Demir, 2023). (Forootan et al., 2022) destaca la relevancia de las redes neuronales para la predicción en sistemas energéticos, subrayando la importancia del preprocesamiento y la segmentación adecuada de los datos. Este hallazgo refuerza la propuesta de integrar redes neuronales y técnicas de

aumentación de datos en el agente DRL, además de incorporar variables hidrológicas para ajustar la predicción en el mercado colombiano.

- **Aumento de Datos (Data Augmentation):** Para abordar el problema de la escasez de datos, se han propuesto métodos de aumento de datos que utilizan Autoencoders (AEs), Autoencoders Variacionales (VAEs) y Redes Generativas Adversarias de Wasserstein con penalización de gradiente (WGAN-GPs) (Demir, 2023). Estos métodos expanden artificialmente los conjuntos de entrenamiento, demostrando reducir el error absoluto medio de los pronósticos del mercado diario (DAM) hasta en un 2.97%.
- **Modelos de Ensamble:** Se ha demostrado que la combinación de pronósticos de diferentes modelos mejora aún más la precisión. El ensamble que promedia los resultados de los modelos AE, VAE, WGAN-GP y TI ha demostrado ser el de mejor rendimiento (Demir, 2023).
- **Redes Recurrentes (GRU):** Para manejar la dimensionalidad en los espacios de estado y acción, se ha utilizado una arquitectura de múltiples agentes equipada con redes Gated Recurrent Unit (GRU) para aproximar las funciones de valor Q en el trading de futuros de materias primas (Massahi & Mahootchi, 2024).

Reinforcement Learning (RL) y Deep Reinforcement Learning (DRL)

El RL y su variante profunda, el DRL, son las metodologías más avanzadas para el diseño de estrategias de trading, ya que modelan el problema como un proceso de decisión secuencial en el que un agente aprende una política óptima a través de la interacción con el entorno del mercado para maximizar una recompensa (generalmente, el beneficio) (Conegundes & Pereira, 2024); (Li et al., 2023) y (Cardo-Miota et al., 2025).

Investigaciones recientes, como (Conegundes & Pereira, 2024) y (Massahi & Mahootchi, 2024) demuestran la eficacia del enfoque multiagente mediante MADRL (Dual-Q MADDPG) para la optimización de estrategias de trading en mercados de futuros. Este enfoque se vuelve especialmente relevante para adaptar el agente inteligente al entorno dinámico del mercado eléctrico, pudiendo además integrar variables externas, como datos hidrológicos, para mejorar la toma de decisiones.

En problemas de trading, en el que se formaliza como un proceso de Decisión de Markov (MDP) o, más comúnmente, como un Proceso de Decisión de Markov Parcialmente Observable (POMDP), ya que el agente no tiene acceso al estado completo del mercado, el agente observa el estado del mercado, elige una acción (comprar, vender, mantener) y recibe una recompensa basada en el resultado financiero (Conegundes & Pereira, 2024). Entre los algoritmos se destacan:

- **Deep Q-Network (DQN) y sus variantes:**
 - **FUT-DRL:** Es una estrategia de *day trading* para el mercado de futuros del Ibovespa que utiliza el algoritmo DQN y que ha demostrado superar a las estrategias tradicionales (Conegundes & Pereira, 2024).
 - **DQN y Double DQN (DDQN) para Futuros de Commodities:** Se ha propuesto un sistema de trading algorítmico para futuros de oro utilizando DQN y su variante Double DQN (DDQN), que ayuda a mitigar la sobreestimación de los valores Q (Massahi & Mahootchi, 2024).
 - **Seguridad y Ataques Adversarios:** La investigación ha comenzado a explorar la seguridad de los algoritmos de RL, demostrando que son vulnerables a ataques de ejemplos adversarios y proponiendo métodos de defensa (Li et al., 2023).
- **Métodos Actor-Crítico:**
 - **A2C y A3C:** Estos algoritmos se han utilizado para desarrollar agentes de trading autónomos que realizan arbitraje estadístico en los mercados de corto plazo (Demir, 2023).
 - **Twin Delayed Deep Deterministic Policy Gradient (TD3):** Se ha aplicado para optimizar la participación en múltiples mercados de electricidad. Este algoritmo utiliza redes críticas gemelas para refinar las estimaciones de retorno (Cardo-Miota et al., 2025).
 - **Soft Actor-Critic (SAC):** Es utilizado en modelos de decisión más avanzados para permitir un aprendizaje robusto y exploratorio (Pan & Jing, 2025).


- Multi-Agent Deep Reinforcement Learning (MADRL):
 - Dual-Q MADDPG: Este algoritmo se ha propuesto para que los productores de energía desarrollen estrategias de cartera óptimas para múltiples contratos de futuros a corto plazo. El uso de una red dual-Q mejora el algoritmo MADDPG tradicional (Wang et al., 2024).
 - Comparativa de Algoritmos MARL: Se ha realizado una evaluación de la fiabilidad de varios algoritmos MARL (MADDPG, MF-MADDPG, Attention-MADDPG), utilizando el "índice de no arrepentimiento" (no-regret index) para medir la proximidad de los resultados al equilibrio de Nash (Zhang et al., 2025).

6. METODOLOGÍA

6.1 Actividades a Realizar y Resultados Esperados

El ciclo de vida de análisis de datos en ambientes de Machine Learning, Deep Learning o Reinforcement Learning define 6 fases (comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluar el modelo y comunicar los resultados). El desarrollo del proyecto se basará en estas fases, esto permitirá llevar control sobre el avance en las actividades del proyecto, con respecto al cronograma de actividades y seguimiento del cumplimiento de los objetivos (Figura 1).

Figura 1. Fases para desarrollar en el proyecto



En la fase 1, comprensión del negocio, consta de algunas actividades para entender el contexto del mercado de futuros de electricidad en Colombia y las necesidades de los compradores no regulados. Para ello, se realizará indagación sobre el dominio del problema para conocer el área de trabajo y como es la interacción del entorno (mercados futuros) entre los diferentes agentes que la componen (generadores, compradores y comercializadores).

Fase 2, comprensión de los datos, incluye los pasos de identificación, recolección y exploración de las fuentes de datos relevantes, consultando con expertos y haciendo investigación secundaria acerca de las posibles variables que influyen en la compra y venta en el mercado de futuros de electricidad en Colombia.

Fase 3, preparación de los datos, Además, se realizará un preprocesamiento, transformación y selección de los

datos antes de modelar y analizar. Durante esta fase se creará el datamart, con el fin de dejar los datos seleccionados y limpios para la siguiente fase de planeación del modelo.

Fase 4, modelado, se identifica la técnica de DRL que se aplicará para desarrollar el agente inteligente prototipo. Luego, se diseñará el entorno, se identificarán los agentes, las acciones y los métodos de recompensa, los cuales son indispensables para este tipo de agente propuesto, se seleccionará la técnica a desarrollar y, junto con los elementos identificados en la fase 3, se construirá y entrenará el agente inteligente prototipo para las estrategias de compra/venta en el mercado de futuros de energía en Colombia.

La fase 5, se centrará en la evaluación de los resultados del agente prototipo, en el que se llevarán a cabo simulación para garantizar el rendimiento de la herramienta. Por último, la fase 6 - comunicar los resultados, se presentará al comité evaluador el desarrollo del trabajo, se identificarán los hallazgos relevantes y se realiza el informe final para mostrar los resultados obtenidos, las conclusiones y recomendación, junto con su respectiva presentación.

En la tabla 1, se relacionan las actividades a realizar en cada una de las fases, los objetivos específicos que cubren cada fase y los entregables esperados. Cabe resaltar que las fases 1 y 2 ya se realizaron durante el desarrollo de esta propuesta.

Tabla 1. Actividades y resultados esperados con relación a cada objetivo específico.

Objetivo	Fases	Actividades	Entregables
Construir un datamart que integre las diferentes características que influyen en el mercado de futuros de energía eléctrica en Colombia para el caso de los compradores no regulados de electricidad.	2. Entendimiento de los Datos 3. Preparación de los Datos	1. Análisis del entorno regulatorio, político, climático, económico. E identificación de riesgos y oportunidades para compradores no regulados. 2. Recolección de datos históricos y externos. 3. Identificación y selección de variables más relevantes para el proceso de compra/venta en mercados futuros de energía en Colombia 4. Integración, limpieza de datos y diseño del esquema del datamart.	1. Documento técnico del análisis del entorno y funcionamiento del mercado de futuros de energía. 2. Datamart funcional con variables relevantes. 3. Documentación técnica del proceso de integración
Entrenar un modelo de decisión basado en Deep Reinforcement Learning (DRL) para la compra y venta de contratos en el mercado colombiano de futuros de electricidad por parte de empresas compradoras no reguladas.	4. Modelado	5. Diseño del entorno de simulación, objetivo y modelo de recompensas del agente. 6. Identificación, selección y entrenamiento el agente utilizando una técnica de DRL. 7. Ajuste de hiperparámetros.	1. Agente DRL entrenado con políticas de compra/venta en mercados de futuros de energía para compradores no regulados de electricidad. 2. Código fuente del agente. 3. Documentación técnica del agente.

Evaluar el rendimiento del agente prototipo en los resultados de la estrategia de compra y venta en los mercados futuros de energía eléctrica en Colombia.	5. Evaluación del Modelo 6. Despliegue	8. Definición de métricas de evaluación. 9. Implementación de simulaciones y comparación de resultados.	1. Reporte comparativo de rendimiento del agente. 2. Conclusiones y recomendaciones para implementación futura.
--	---	--	--

6.2 Cronograma de Actividades

El trabajo de grado se desarrollará durante la segunda mitad del año 2025 y primer trimestre del año 2026. La tabla 2, muestra el cronograma y duración de las actividades que se realizarán.

Tabla 2. Cronograma de Actividades

Objetivo	Actividad	Duración (semanas)	2025												2026											
			Septiembre				Octubre				Noviembre				Diciembre				Enero				Febrero			
			1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
1	1	5																								
	2	4																								
	3	3																								
	4	4																								
2	5	3																								
	6	6																								
	7	4																								
3	8	3																								
	9	6																								

7. PRESUPUESTO

7.1 Presupuesto general

En la tabla 3 se presenta el presupuesto general para el desarrollo exitoso del presente proyecto.

Tabla 3. Presupuesto general del proyecto.

RUBROS	VALOR (Pesos)
Personal	\$ 75'600.000
Hardware	\$ 20'000.000
Software	\$ 1'000.000
Publicaciones	\$ 0
Imprevistos	\$ 150.000
TOTAL PRESUPUESTO	\$ 96'750.000

7.2 Presupuesto detallado

En las siguientes tablas se evidencia el presupuesto detallado por cada rubro y la fuente de financiación.

Tabla 4. Presupuesto de personal.

Nombre De Participante	Función	Meses De Vinculación	Dedicación (H/S)	Costo Por Hora	Costo Total (Pesos)	Fuente de financiación
Diego Manotas Ph.D.	Director	9	2	\$ 150.000	\$ 10'800.000	Universidad del Valle
Orlando Joaqui Ph.D.	Director	9	2	\$ 150.000	\$ 10'800.000	Universidad del Valle
Jhon Tascón	Desarrollador	9	15	\$ 50.000	\$ 27'000.000	Autor
Juan Chacón	Desarrollador	9	15	\$ 50.000	\$ 27'000.000	Autor
TOTAL COSTO PERSONAL					\$ 75'600.000	

Tabla 5. Presupuesto de Hardware.

Equipo	Justificación	Costo (Pesos)	Fuente de financiación
Portátil	Portátiles para desarrollo	\$ 20'000.000	Autores
TOTAL COSTO HARDWARE		\$ 20'000.000	

Tabla 6. Presupuesto de Software.

Concepto	Justificación	Costo (Pesos)	Fuente de financiación
Recolección de noticias	Requerido para el análisis del entorno y su interacción con el agente	\$ 1'000.000	Autores
TOTAL COSTO HARDWARE		\$ 1'000.000	

Tabla 7. Presupuesto de papelería y otros rubros.

Concepto	Justificación	Costo (Pesos)	Fuente de financiación
Imprevistos/Otros	Material requerido físicamente, impresión del documento final.	\$ ±150.000	Autores
TOTAL COSTO OTROS		\$ ±150.000	

8. REFERENCIAS

- Ansari, Y., Yasmin, S., Naz, S., Zaffar, H., Ali, Z., Moon, J., & Rho, S. (2022). A Deep Reinforcement Learning-Based Decision Support System for Automated Stock Market Trading. *IEEE Access*, 10, 127469-127501. <https://doi.org/10.1109/ACCESS.2022.3226629>
- Arias, S., Santa-Alvarado, A. M., & Salazar, H. (2024). The Impact of a Market Maker in an Electricity Market. *Energies*, 17(16), 4042. <https://doi.org/10.3390/en17164042>
- Cardo-Miota, J., Beltran, H., Pérez, E., Khadem, S., & Bahloul, M. (2025). Deep reinforcement learning-based strategy for maximizing returns from renewable energy and energy storage systems in multi-electricity markets. *Applied Energy*, 388, 125561. <https://doi.org/10.1016/j.apenergy.2025.125561>
- COMISIÓN DE REGULACIÓN DE ENERGÍA Y GAS. (2024, febrero 7). *RESOLUCIÓN No.101 036 DE* 2024. https://gestornormativo.creg.gov.co/gestor/entorno/docs/originales/Resoluci%C3%B3n_CREG_101_036_2024/
- Conegundes, L., & Pereira, A. C. M. (2024). A Methodology for Developing Deep Reinforcement Learning Trading Strategies: A Case Study in the Futures Market. *2024 IEEE Symposium on Computational Intelligence for Financial Engineering and Economics (CIFEr)*, 1-10. <https://doi.org/10.1109/CIFEr62890.2024.10772851>
- Demir, S. (2023). *Statistical Arbitrage Trading on Electricity Markets Using Deep Reinforcement Learning* [Tesis]. Eindhoven University of Technology.
- Derivex S.A., & Cámara de Riesgo Central de Contraparte de Colombia S.A. (2018). *Propuesta: Mercado de Derivados Estandarizados de Commodities Energéticos como mecanismo para la comercialización de energía eléctrica en Colombia, para que sus precios sean reconocidos en el componente de costos de compras de energía al usuario regulado* (No. Circular 017-20, Anexo 1). Derivex S.A; Cámara de Riesgo Central de Contraparte de Colombia S.A. [https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/2318e3991fb54c1605258528007f8f14/\\$FILE/Circular017-20%20Anexo.pdf](https://gestornormativo.creg.gov.co/Publicac.nsf/52188526a7290f8505256eee0072eba7/2318e3991fb54c1605258528007f8f14/$FILE/Circular017-20%20Anexo.pdf)
- Forootan, M. M., Larki, I., Zahedi, R., & Ahmadi, A. (2022). Machine Learning and Deep Learning in Energy Systems: A Review. *Sustainability*, 14(8), 4832. <https://doi.org/10.3390/su14084832>
- Hambly, B., Xu, R., & Yang, H. (s. f.). *Recent Advances in Reinforcement Learning in Finance*.
- He, Q., Wang, J., Shi, R., He, Y., & Wu, M. (2024). Enhancing renewable energy certificate transactions through reinforcement learning and smart contracts integration. *Scientific Reports*, 14(1), 10838. <https://doi.org/10.1038/s41598-024-60527-3>
- Islam, S. N. (2024). A Review of Peer-to-Peer Energy Trading Markets: Enabling Models and Technologies. *Energies*, 17(7), 1702. <https://doi.org/10.3390/en17071702>
- Lago, J., De Ridder, F., & De Schutter, B. (2018). Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221, 386-405. <https://doi.org/10.1016/j.apenergy.2018.02.069>
- Lami, B., Alsolami, M., Alferidi, A., & Slama, S. B. (2025). A Smart Microgrid Platform Integrating AI and Deep Reinforcement Learning for Sustainable Energy Management. *Energies*, 18(5), 1157. <https://doi.org/10.3390/en18051157>
- Li, D., Yang, Q., Ma, L., Peng, Z., & Liao, X. (2023). Offense and defence against adversarial sample: A reinforcement learning method in energy trading market. *Frontiers in Energy Research*, 10, 1071973. <https://doi.org/10.3389/fenrg.2022.1071973>
- Majcher, K., Musiał, M., Pakos, W., Róžański, A., Sobótka, M., & Trapko, T. (2021). A Systematic

- Review of HPM Energy Absorbers for Building Applications. *Energies*, 14(19), 6061. <https://doi.org/10.3390/en14196061>
- Marin, J. B., & Marin, H. G. (2022). Oligopoly and Collusion in the Colombian Electricity Market. *International Journal of Energy Economics and Policy*, 12(3), 125-134. <https://doi.org/10.32479/ijeep.12883>
- Massahi, M., & Mahootchi, M. (2024). A deep Q-learning based algorithmic trading system for commodity futures markets. *Expert Systems with Applications*, 237, 121711. <https://doi.org/10.1016/j.eswa.2023.121711>
- Ministerio de Minas y Energía. (2021). *Transición energética: Un legado para el presente y el futuro de Colombia*. https://www.minenergia.gov.co/documents/5856/TRANSICION_ENERGETICA_COLOMBIA_BID-MINENERGIA-2403.pdf
- Pan, Z., & Jing, Z. (2025). Decision-making and cost models of generation company agents for supporting future electricity market mechanism design based on agent-based simulation. *Applied Energy*, 391, 125881. <https://doi.org/10.1016/j.apenergy.2025.125881>
- Pereira, H., Gomes, L., & Vale, Z. (2024). *Optimizing Participation in The Local Energy Market Using a Deep Reinforcement Learning Approach*. Volume 45: Energy Transitions toward Carbon Neutrality: Part VIII. <https://doi.org/10.46855/energy-proceedings-11087>
- Restrepo-Trujillo, J., Moreno-Chuquen, R., Jiménez-García, F., Flores, W., & Chamorro, H. (2022). Scenario Analysis of an Electric Power System in Colombia Considering the El Niño Phenomenon and the Inclusion of Renewable Energies. *Energies*, 15(18), 6690. <https://doi.org/10.3390/en15186690>
- Rita Uchenna Attah, Baalah Matthew Patrick Garba, & Olakojo Yusuff Ogunsola. (2022). The future of energy and technology management: Innovations, data-driven insights, and smart solutions development. *International Journal of Science and Technology Research Archive*, 3(2), 281-296. <https://doi.org/10.53771/ijstra.2022.3.2.0114>
- Rodriguez, D. E., Trespalacios, A., & Pantoja, J. O. (2022). *Risk Premium in Colombia Wholesale Electricity Market*.
- Valora Analitik. (2025). *Precio de energía en bolsa cayó 62,01 % en marzo de 2025: Quedó en \$236,37/kWh*. <https://es-us.noticias.yahoo.com/precio-energ%C3%ADa-bolsa-cay%C3%B3-62-191500536.html>
- Waldow, F., Schnaubelt, M., Krauss, C., & Fischer, T. G. (2021). Machine Learning in Futures Markets. *Journal of Risk and Financial Management*, 14(3), 119. <https://doi.org/10.3390/jrfm14030119>
- Wang, Y., Shi, E., Xu, Y., Hu, J., & Feng, C. (2024). Short-Term Electricity Futures Investment Strategies for Power Producers Based on Multi-Agent Deep Reinforcement Learning. *Energies*, 17(21), 5350. <https://doi.org/10.3390/en17215350>
- Weron, R. (2014). Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4), 1030-1081. <https://doi.org/10.1016/j.ijforecast.2014.08.008>
- Zhang, H., Qiu, D., Kok, K., & Paterakis, N. G. (2025). Reliability assessment of multi-agent reinforcement learning algorithms for hybrid local electricity market simulation. *Applied Energy*, 389, 125789. <https://doi.org/10.1016/j.apenergy.2025.125789>